

ROTEIRO DE AULA PRÁTICA

Engenharia de Requisitos para ML com GR4ML

Caderno de Exercícios do Grupo
Preencha os templates de cada fase durante a aula

Centro de Informática — CIn/UFPE
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

Grupo (nome dos integrantes)	Projeto da disciplina
<i>Tiago Lira</i>	Engenharia de Software para IA
<i>Tayná Martins Ramos</i>	
<i>Theilon Macêdo</i>	
<i>Paulo Fraga de Sousa</i>	
<i>Michelle Marques Rosa</i>	
<i>Hermes Laurentino de Santana Neto</i>	
<i>Filipe Torres Pontes</i>	
<i>Emmanuel Victor Barbosa Sampaio</i>	

Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

 **Objetivo da atividade**

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

Cronograma sugerido

Fase	Duração	Conteúdo
Fase 0 — Alinhamento	20 min	Escopo do projeto, stakeholder principal e dor de negócio
Fase 1 — Business View	45 min	Atores, objetivos, indicadores, decisões e perguntas de negócio
Fase 2 — Analytics Design View	45 min	Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas
Fase 3 — Data Preparation View	45 min	Fontes de dados, transformações e pipeline até o dataset final
Fase 4 — Dos modelos aos requisitos	30 min	Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados

As três visões do GR4ML, em uma tabela

Visão	Pergunta que responde	Quem pensaria assim, na vida real	O que sai dela
1. Business View	Quem precisa de quê, e por quê?	Gestor / dono do produto	Diagrama Ator → Goal → Decision Goal → Question Goals
2. Analytics Design View	Que modelo resolve isso, com qual qualidade?	Cientista de dados	Tarefas de ML, algoritmos e métricas ligadas aos softgoals
3. Data Preparation View	De onde vêm os dados e como chegam prontos?	Engenheiro de dados	Pipeline de dados brutos até features prontas



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTES PASSOS: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

Em conjunto com o time de planejamento da Digital Aligner, empresa de alinhadores invisíveis, identificamos a

necessidade de padronizar as 5 fotos intraorais enviadas pelos dentistas, reduzindo o retrabalho manual. O

Classificador de Imagens Odontológicas é um projeto que identifica automaticamente a vista de cada foto e a

classifica corretamente, automatizando a entrada de dados na plataforma de pedidos, posicionando as imagens no

lugar certo e economizando o tempo gasto atualmente em correções manuais.

1 FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?

💡 Exemplos de Atores

- *Streaming* → *Gerente de Retenção de Clientes*
- *Fraude* → *Gerente de Prevenção a Fraudes*
- *Saúde* → *Médico Oncologista*
- *Hospital (fluxo de atendimento)* → *Coordenador de Enfermagem*

🔑 **ENTREGÁVEL DESTE PASSO:** Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).

Nome do Ator	Papel na organização
<i>Gerente do Centro de Planejamento</i>	Gerencia os processos de planejamento
<i>Cadista</i>	Quem recebe as fotos e faz as eventuais correções
<i>Dentista</i>	Quem insere as fotos na plataforma

PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

💡 Exemplo (streaming)

- *Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"*
- *Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%*
- *Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."*

🔑 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

Ator	Goal (objetivo)	Indicador (métrica)	Expectativas de qualidade (informal)
<i>Dentista</i>	Facilitar a entrada das fotos na plataforma, que	% fotos no local correto	Facilidade para não ter que subir mais as fotos uma a uma

Ator	Goal (objetivo)	Indicador (métrica)	Expectativas de qualidade (informal)
	atualmente demanda subir uma a uma e ainda acertar o local de cada uma das fotos na plataforma		
<i>Cadista</i>	Zerar o retrabalho com realocações das fotos na plataforma	% fotos no local correto	Zero erros quando essas fotos chegarem para o cadista trabalhar com as mesmas
<i>Gerente</i>	Aumentar a produtividade do time	Redução do prazo de entrega	Atender à demanda da Diretoria por aumento de produtividade do time

PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.

Exemplos

- *Streaming*: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- *Fraude*: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- *Hospital*: "Decidir qual paciente deve ser atendido primeiro na triagem"

Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?

 **ENTREGÁVEL DESTES PASSOS:** Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.

Cadista precisa decidir quais pedidos são aprovados automaticamente ou não.

Dentista precisa decidir se o conjunto de 5 fotos está completo para envio ou se alguma vista deve ser refeita, a cada pedido.

Gerente precisa decidir se a qualidade do classificador é suficiente para manter o fluxo automático ou se o processo deve retornar à revisão manual, a cada ciclo de avaliação.

PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.

Exemplos

- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal


- Fraude: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- Hospital: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real

ENTREGÁVEL DESTE PASSO: Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.

Question Goal (a pergunta)	Tipo	Tempo (passado/presente/futuro)	Frequência
<i>Essas fotos servem para o planejamento?</i>	O que	Presente	A cada pedido
<i>O quão bem as imagens foram classificadas?</i>	O que	Presente	A cada pedido
<i>Alguma vista não foi identificada?</i>	O que	Presente	A cada pedido

Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.



CHECKPOINT

Antes de seguir para a Fase 2, mostrem esse diagrama ao professor. Nenhum grupo deve avançar sem ter clareza total sobre o problema de negócio.

2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

Tipo	O que faz	Exemplo
Preditiva	Prever um valor futuro ou desconhecido	Prever se o cliente vai cancelar
Descritiva	Resumir/explicar o conjunto de dados	Agrupar clientes em perfis de comportamento
Prescritiva	Recomendar a melhor ação entre opções	Recomendar qual desconto oferecer a cada cliente

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

Question Goal	Tipo de análise	Justificativa
Qual é a vista de cada imagem intraoral e qual a probabilidade atribuída às cinco classes?	Preditiva	Inferir um rótulo desconhecido entre cinco classes e estima a distribuição de probabilidade.
O caso contém uma imagem selecionada para cada uma das cinco vistas esperadas?	Descritiva	Resume as predições do caso para verificar cobertura das cinco vistas e identificar ausências.
Qual é a acurácia do modelo em sujeitos não vistos, sem vazamento entre treino e teste?	Descritiva	Resume o desempenho observado no conjunto de teste e permite comparar os modelos candidatos.

PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

Exemplo (streaming — "prever cancelamento")

- *Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)*
- *Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural*

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
Identificar a vista de cada imagem	Classificação multiclasse (5 classes)	PCA + SVC (RBF); CNN PyTorch treinada do zero; ResNet-18 pré-treinada + classificador linear/fine-tune.
Representar características visuais discriminativas	Extração / redução de características	StandardScaler + PCA; features aprendidas pela CNN; ResNet-18 com vetor de 512 dimensões.
Verificar cobertura das cinco vistas no caso	Agregação/regra de negócio sobre as predições	Regra Determinística

PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

Exemplos, com a origem no negócio

- "Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão
- "Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade
- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

Softgoal	Origem (frase do stakeholder ou 'técnico')
Alta qualidade global e por classe	Reduzir realocações manuais e evitar que uma vista seja sistematicamente confundida com outra.
Baixa latência de inferência do conjunto de imagens	A classificação automática não deve introduzir atraso perceptível no fluxo do Dentista/Cadista.
Cobertura explícita das cinco vistas no caso	O Cadista precisa saber quando uma vista não foi encontrada para encaminhar o caso à revisão.

PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

 O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

 **Exemplos de vínculo Softgoal → Métrica**

- *Fraude: "Evitar perturbar clientes inocentes" → alta Precisão / baixa taxa de Falso Positivo*
- *Saúde: "Explicabilidade" → uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis*
- *Streaming: "Compatível com o prazo semanal" → tempo de inferência em lote < 2h para toda a base*

 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

Algoritmo	Softgoal 1 (métrica)	Softgoal 2 (métrica)	Softgoal 3 (métrica)
<i>Rede Neural</i>	Baixa taxa de Falso Positivo / Alta Precisão	Tempo de inferência	
<i>SVC</i>	Baixa taxa de Falso Positivo / Alta Precisão	Tempo de inferência	
<i>XGBoost</i>	Baixa taxa de Falso Positivo / Alta Precisão	Tempo de inferência	

Conclusão do grupo — qual algoritmo escolheriam e por quê:

Os algoritmos de Machine Learning e Deep Learning apresentam boa performance no processamento e

classificação de imagens.

PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.

 **Exemplo (streaming)**

- *"Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."*

 **ENTREGÁVEL DESTE PASSO:** Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.

Se o modelo acertar ao menos 90% da classificação das imagens, a redução do trabalho dos Cadistas será considerada plena.

 CHECKPOINT

Antes de seguir para a Fase 3, garantam que cada Softgoal tem uma métrica associada — não deixem nenhum 'bonito no papel'.

3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o quê assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

Fonte de dados (tabela)	Principais campos/atributos
Dataset bruto por sujeito	Uma subpasta por paciente/sujeito, com as cinco imagens JPEG intraorais esperadas.
Rótulos das vistas	Derivados do nome do arquivo: intraoral-frontal, intraoral-inferior, intraoral-superior, intraoral-lateral-direita e intraoral-lateral-esquerda.

PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

Nº	Transformação aplicada	Tabela(s) de origem
1	Tratamento das dimensões das imagens • PCA/SVC = conversão para luminância (YCbCr→Y), resize 128×128, vetorização e padronização com StandardScaler;	Imagens odontológicas intraorais

Nº	Transformação aplicada	Tabela(s) de origem
	• CNN = resize, conversão para escala de cinza/luminância por padrão, transformação em tensor e normalização; • ResNet-18 = processamento RGB com resize/crop, ColorJitter no treino e normalização ImageNet.	
2	Extração de características pela rede neural pré-treinadas	<i>Imagens odontológicas intraorais</i>
3.	Classificacao da vista pelo classificador treinado	Imagens Odontologias Intraorais
4	Agregacao por Caso (seleção da imagem com maior confiança por vista)	Resultado da predição por imagem

PASSO 3.3 Dataset final e Pipeline

Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.


💡 Exemplo de dataset preparado (streaming)

• Colunas: *Cliente_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*


🔗 **ENTREGÁVEL DESTE PASSO:** Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

- No nosso modelo usamos dados não estruturados (ou não tabulares), imagens, e destas usamos características extraídas por meio de métodos de aprendizagem automatizada: CNN ou por meio de métodos estatísticos clássicos como no caso do PCA.

Pipeline de treino



Pipeline de inferência



CHECKPOINT

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

Ferramentas recomendadas

Como o GR4ML estende conceitos do i* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
 - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
 - Nuvens → Softgoals
 - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

Verificação final

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

Preenchem a frase com o projeto de vocês

“Para ajudar o Cadista a decidir quais pedidos são aprovados automaticamente, respondendo à pergunta 'qual é a vista de cada imagem intraoral e qual a probabilidade atribuída às cinco classes', vamos usar a ResNet-18 com transfer learning, que satisfaz os softgoals de alta qualidade por classe, baixa latência de inferência e cobertura explícita das cinco vistas, medidos por acurácia de teste por classe, tempo de inferência e % de vistas identificadas por caso, usando o dataset preparado de imagens normalizadas por sujeito (sem vazamento treino/teste), vindo das pastas de sujeitos com as 5 fotos intraorais nomeadas por vista. Isso deve impactar o indicador '% de fotos no local correto, elevando para pelo menos 90%, praticamente eliminando o retrabalho manual do Cadista.’”

FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.

Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitación só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

Mapa de tradução: do elemento do GR4ML ao tipo de requisito

Elemento já modelado	Tipo de requisito gerado	Pergunta-guia para redigir
Decision Goal + Question Goal + Insight (Fase 1)	Requisito Funcional (RF)	O que exatamente o sistema precisa calcular ou entregar?
Softgoal + Métrica associada (Passo 2.3–2.4)	Requisito Não-Funcional (RNF)	Que qualidade o sistema deve garantir, e como ela será medida?
Entidades + Dataset Preparado + Transformações (Fase 3)	Requisito de Dados (RD)	Que dados precisam ser coletados, integrados e tratados, e de onde vêm?
Indicador (Passo 1.2)	Critério de Aceitação do conjunto de requisitos	Como saberemos, no negócio, que os requisitos implementados geraram valor real?

PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).

 **Modelo de frase (template)**

- "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."

 **Exemplo preenchido (streaming)**

- "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."

 **ENTREGÁVEL DESTES PASSOS:** Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-01	O sistema deve classificar cada imagem JPEG intraoral em uma das cinco vistas (frontal, inferior, superior, lateral direita ou lateral esquerda)	Question Goal: identificar a vista / Decision Goal do Cadista
RF-02	O sistema deve processar uma pasta de um caso e retornar um mapa das cinco vistas para os arquivos classificados, escolhendo a maior confiança e verificar se uma vista não foi identificada.	Question Goal: cobertura das 5 vistas / Decision Goal do Cadista

PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.

 **Modelo de frase (template)**

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."

 **Exemplos preenchidos**

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)

 **ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

ID	Requisito Não-Funcional (RNF)	Origem no modelo (Softgoal/Métrica)
RNF-01	O sistema deve atingir acurácia de teste de pelo menos 90% na classificação das cinco vistas, medida em conjunto de teste formado por sujeitos não vistos no treino.	Softgoal: alta qualidade / Acurácia $\geq 90\%$
RNF-02	O sistema deve classificar uma imagem com melhor performance visando diminuir a latência.	Baixa latência de inferência.
RNF-03	O sistema deve reportar 'Not found' para qualquer uma das cinco vistas não identificadas em um caso, garantindo cobertura explícita de 100% das vistas verificáveis	Cobertura explícita das cinco vistas

PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.

Modelo de frase (template)

• "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."

Exemplo preenchido (streaming)

• "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."

 **ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD-01	O sistema deve coletar/aceitar, no dataset de treinamento, imagens JPEG das cinco vistas por sujeito, usando os nomes reconhecidos para derivar os rótulos; arquivos com nome ou extensão fora do padrão não devem compor o treino.	RF-01, RF-02
RD-02	O sistema deve aplicar o pipeline específico do modelo antes da classificação: luminância+StandardScaler+PCA para PCA/SVC; Resize/Grayscale/Normalize para CNN; e crop/normalização ImageNet para ResNet-18.	RF-01, RF-02

PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

Modelo de frase (template)

- "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

Exemplo preenchido (streaming)

- "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTE PASSO:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

Este conjunto de requisitos será considerado bem-sucedido se o percentual de fotos posicionadas corretamente

(RNF-01) atingir pelo menos 90% e o retrabalho manual de realocação pelo Cadista cair a praticamente zero,

observado nos primeiros meses de uso pela Digital Aligner.

Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.

Estrutura do documento a ser entregue

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

Reflexão crítica do grupo

O ML foi necessário porque nomear/posicionar manualmente 5 fotos por pedido é o gargalo real, uma regra

fixa não resolve fotos fora de padrão ou mal nomeadas.

Normalizar os Softgoals revelou exigências que não estavam explícitas na conversa inicial: "baixa latência" e

"cobertura das 5 vistas" só viraram requisito mensurável (RNF-02/03) depois do Passo 2.3–2.4, no discurso

inicial do stakeholder isso era só "não travar o fluxo" e "avisar quando faltar foto".
